

#### APACHE SPARK: QUICK INTRO & DEMO

Novembre 2016 ANDREA BECCARIS



#### **ANDREA BECCARIS**

# FULL-STACK DEVELOPER @ TOP-IX NETWORK & SOFTWARE ENGINEER #CODENINJA AND #SPORTADDICTED

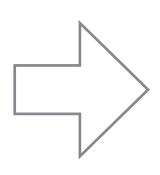
andrea.beccaris@top-ix.org https://it.linkedin.com/in/andreabeccaris





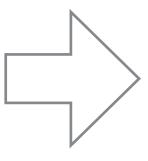
#### DALLO SCRIPTING AI FRAMEWORK







PYTHON + MRJOB





Apache Spark è un framework open-source per l'analisi di grandi quantità di dati su cluster, nato per essere veloce e flessibile.

```
/ Veloce nel configurare un CLUSTER (riduce i tempi di kickstart)
```

/ Veloce nello scrivere applicazioni (supporta diversi linguaggi: Python, Scala, Java,...)

/ Veloce nell'eseguire applicazioni (nasce con questo focus)



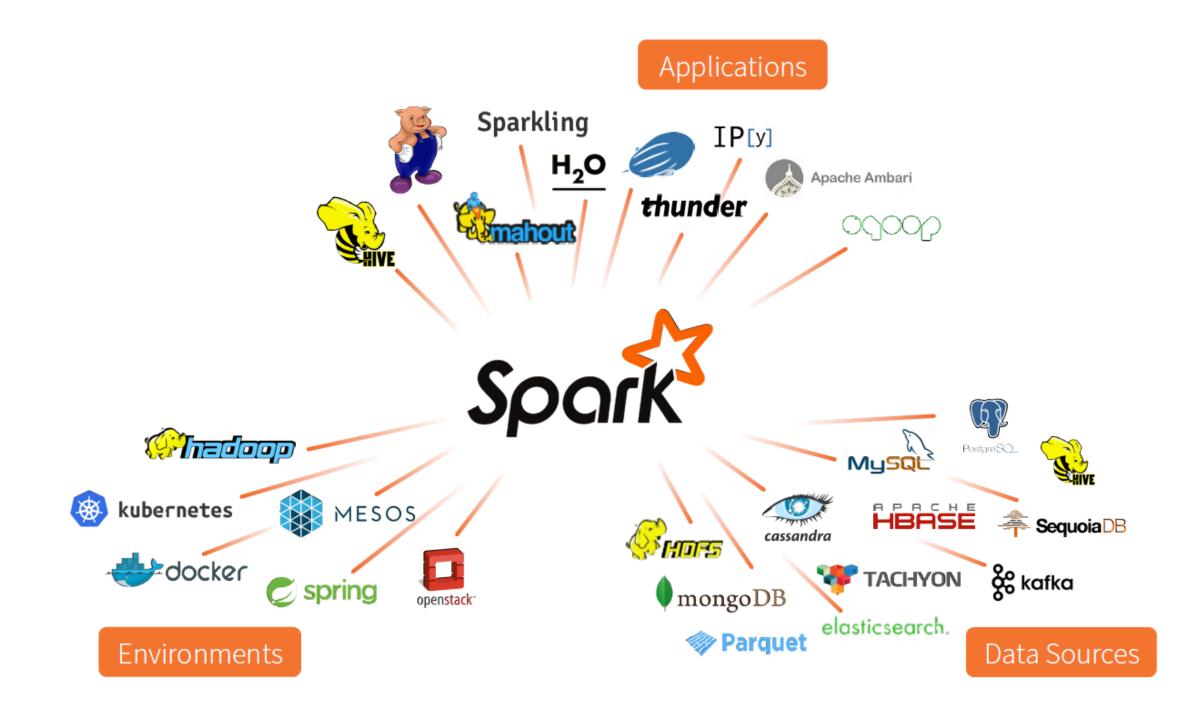
#### IL PROGETTO DI DATA PROCESSING OPEN-SOURCE PIÙ ATTIVO

#### COMMUNITY DI SVILUPPATORI IN CRESCITA

	2014	2015
Contributors	255	730
Push/month	75	135
Lines of Code	175,000	400,000



#### **APACHE SPARK ECOSYSTEM**





## APACHE HADOOP "VS" APACHE SPARK MAPREDUCE (MRJOB) "VS" APACHE SPARK

I due framework di casa Apache vengono spesso descritti come mutualmente esclusivi, ma così non è.

Spark è costruito a partire da Hadoop con il dichiarato obiettivo di migliorarne le prestazioni nel campo MapReduce.

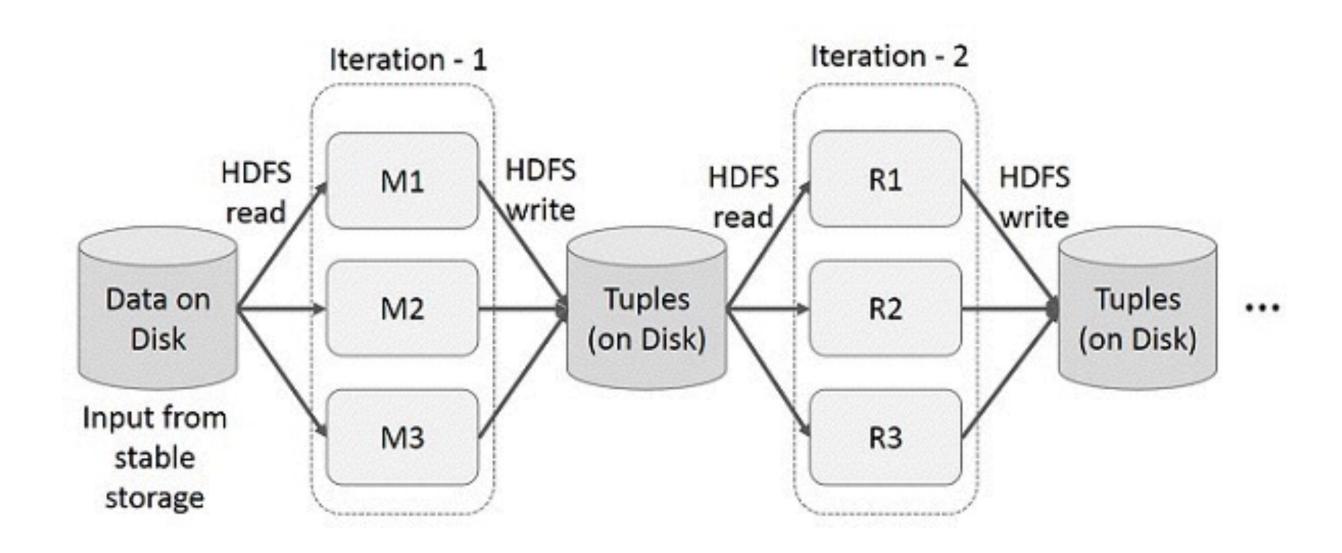


#### SPARK è ottimizzato per:

/ Minimizzare le operazioni di lettura e scrittura su disco

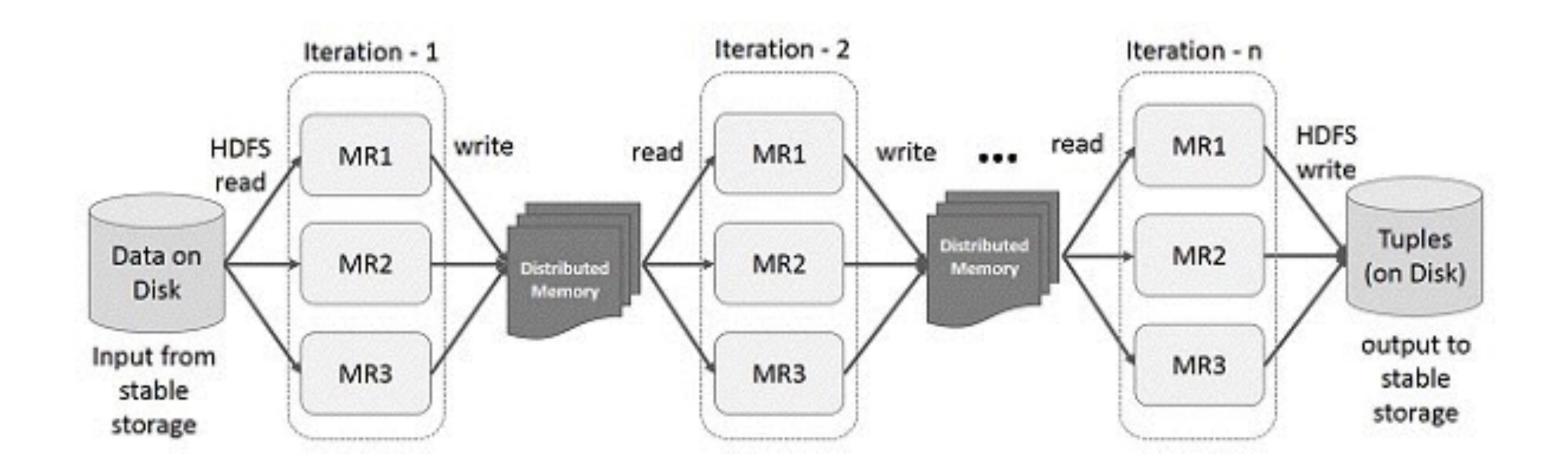
/ Migliorare le prestazioni di azioni ripetute, iterative, cicli

#### **COME FUNZIONA MAPREDUCE STANDARD**





#### **COME FUNZIONA APACHE SPARK**





	Hadoop MR	Spark	Spark 1PB
Data size	102.5TB	100TB	1PB
Nodes	2100	206	190
Cores	50400 (phy)	6592 (virt)	6080 (virt)
Time	72 mins	23 mins	234 mins
Rate	1.42TB/min	4.27TB/min	4.27TB/min
Rate (node)	0.67GB/min	20.7GB/min	22.5GB/min



#### **APACHE SPARK: COMPONENTI**

Spark SQL

Spark Streaming MLlib (machine learning)

GraphX (graph)

Apache Spark



#### **APACHE SPARK: COMPONENTI**

Spark SQL

Spark Streaming MLlib (machine learning)

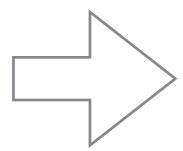
GraphX (graph)

Apache Spark



#### Il CORE di SPARK si occupa di:

- / gestione della memoria
- / gestione della rete
- / gestione dello scheduling
- / failure recovery



GESTIONE RDD
(RESILIENT
DISTRIBUTED
DATASET)



#### **APACHE SPARK: COMPONENTI**

Spark SQL

Spark Streaming MLlib (machine learning)

GraphX (graph)

Apache Spark



Supporta dati strutturati e non strutturati

Permette di eseguire vere e proprie query come su un classico datawarehouse

Implementa un livello di astrazione per i dataset chiamato schemaRDD



#### **APACHE SPARK: COMPONENTI**

Spark SQL

Spark Streaming MLlib (machine learning)

GraphX (graph)

Apache Spark



È possibile utilizzare spark per l'analisi in tempo reale di dati o flussi di dati.
(es. file di log)





#### **APACHE SPARK: COMPONENTI**

Spark SQL

Spark Streaming MLlib (machine learning)

GraphX (graph)

Apache Spark



Include nativamente una libreria altamente ottimizzata dedicata al machine learning



9x (performance) rispetto all'analoga in Hadoop



#### **APACHE SPARK: COMPONENTI**

Spark SQL

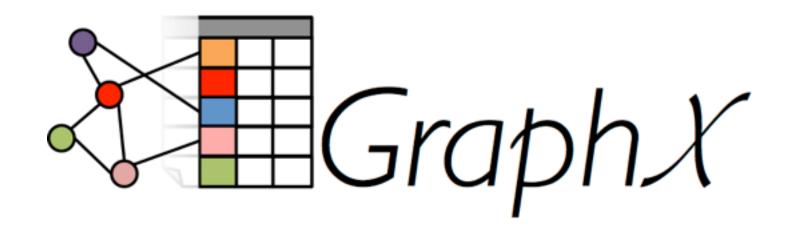
Spark Streaming MLlib (machine learning)

GraphX (graph)

Apache Spark



Offre NATIVAMENTE la possibilità di utilizzare algoritmi tipici dell'analisi dei grafi come il pagerank.



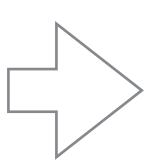


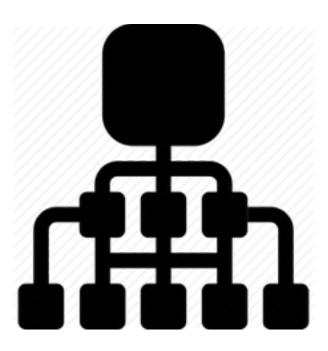
#### ARCHITETTURA DI APACHE SPARK



### Pensato perchè il codice scritto in locale funzioni immediatamente su un cluster

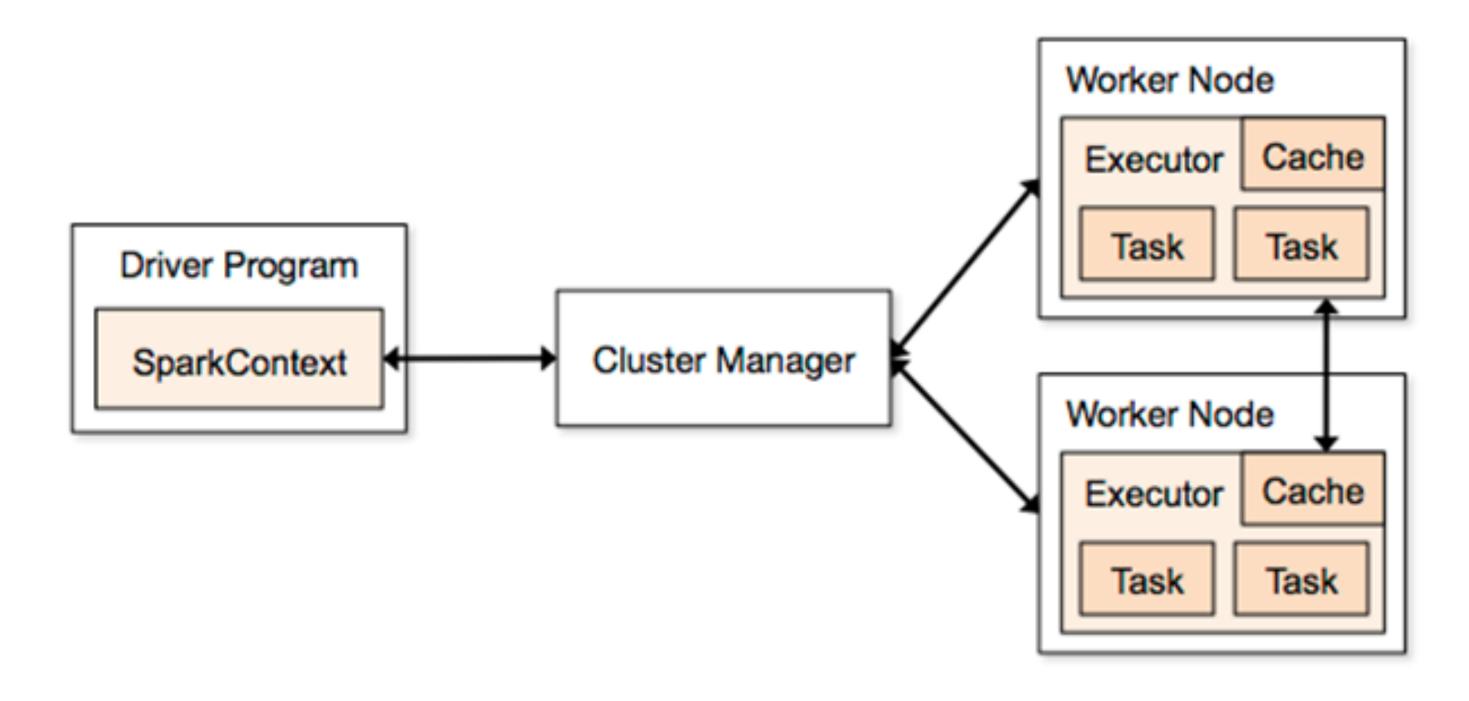






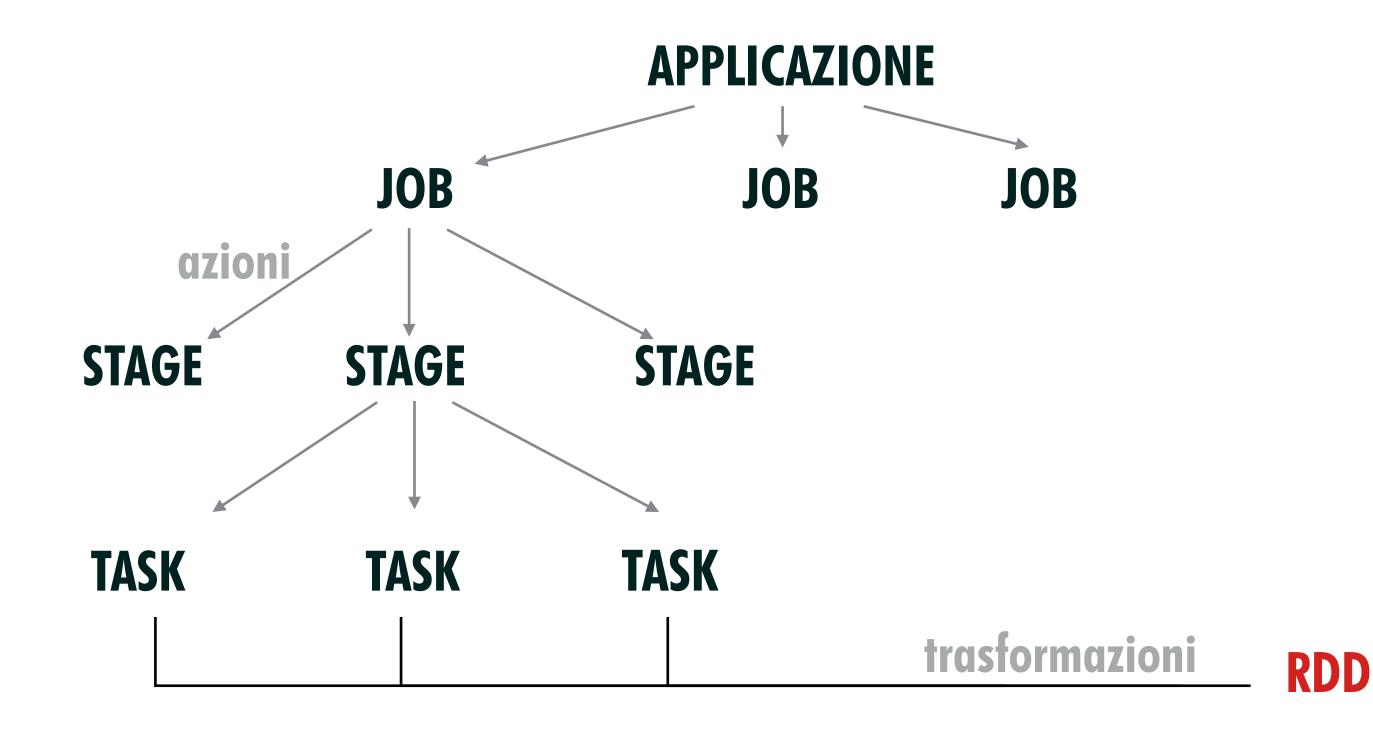


#### **APACHE SPARK: ARCHITETTURA**





#### **APACHE SPARK: ARCHITETTURA**





### RDD RESILIENT DISTRIBUTED DATASET

**RESILIENT** >> **FAILURE RECOVERY** 

**DISTRIBUTED** > PARTIZIONATO SU DIVERSI NODI

DATASET >> COLLEZIONE DI ELEMENTI

**RESILIENT** >> FAILURE RECOVERY

Per poter ricostruire il dato ho bisogno di uno "storico"

**RESILIENT** >> FAILURE RECOVERY

Per poter ricostruire il dato ho bisogno di uno "storico"

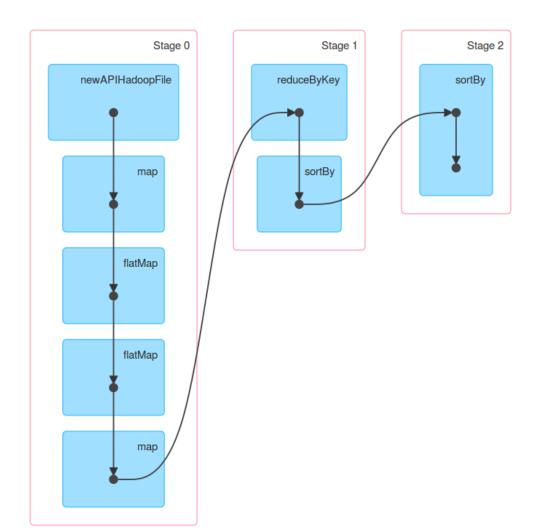
**DAG** 



### DAG



#### DIRECT ACYCLING GRAPH

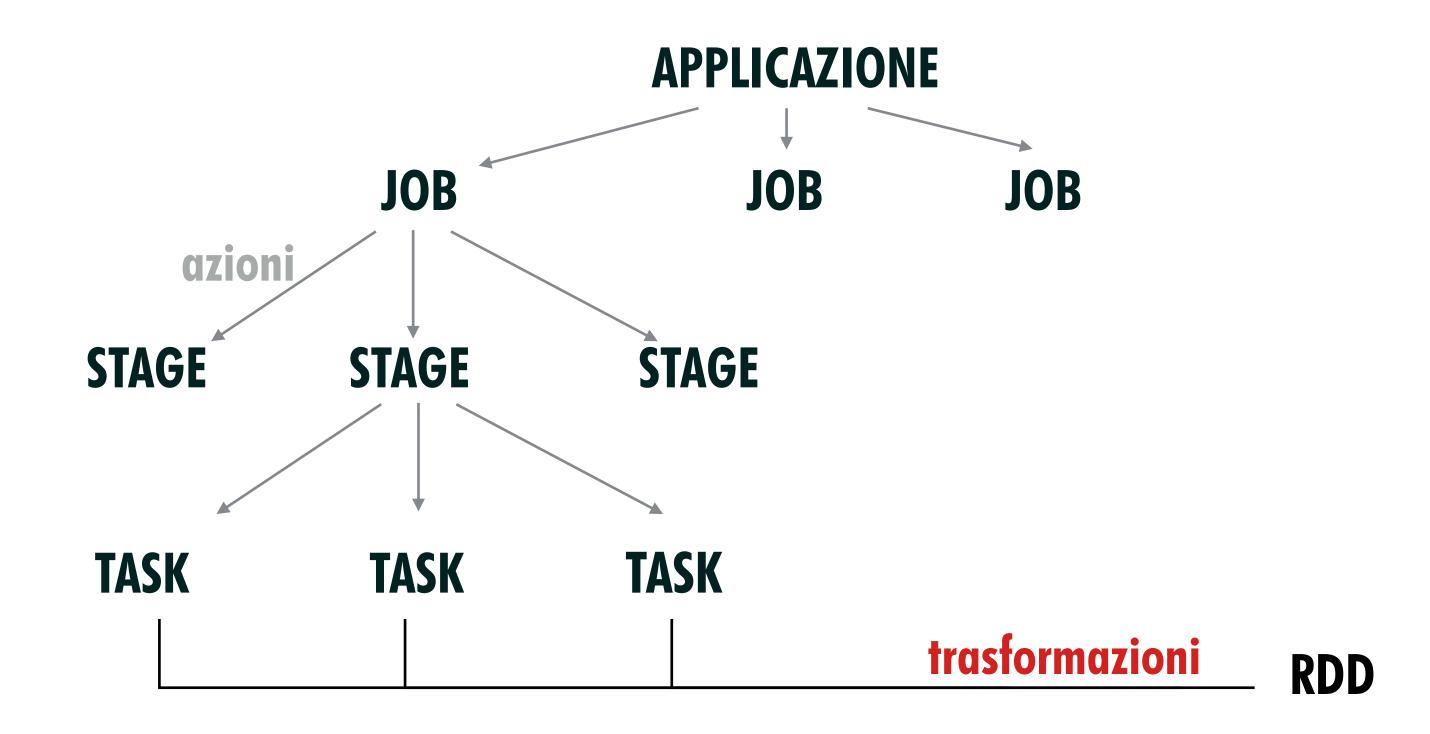


il DAG è un grafo in cui i nodi sono gli RDD/trasformazioni e le frecce sono le dipendenze

ogni job ha il suo dag!



#### **APACHE SPARK: ARCHITETTURA**



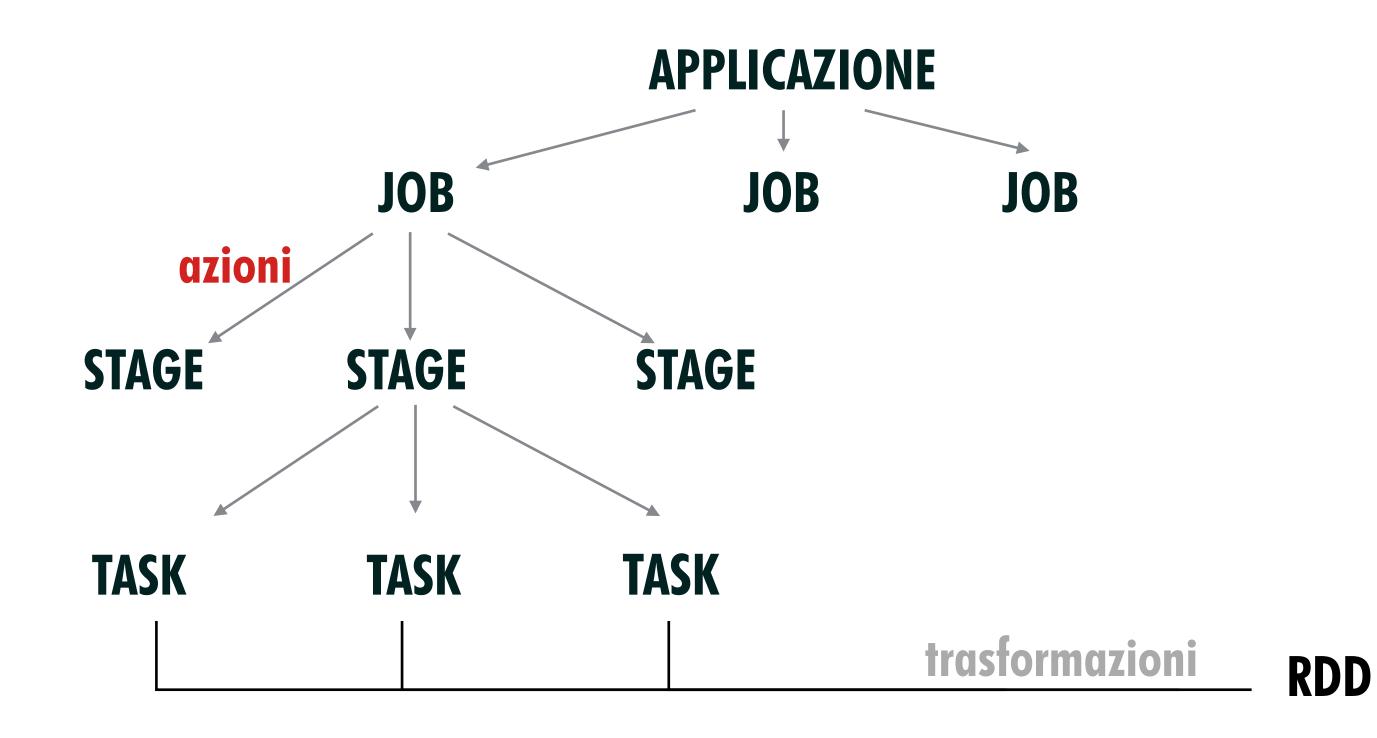


#### **TRASFORMAZIONI**

- / Operano su RDD "modificandone" il contenuto
- / Non vengone eseguite fino alla richiesta di output (LAZY)
- / Gestione dello scheduling
- / Possono essere invocate in cascata
- / Ad ogni trasformazione viene aggiunto un nodo al DAG



#### **APACHE SPARK: ARCHITETTURA**





#### **AZIONI**



- / Materializzano l'RDD scatenando risultati immediati
- / Vengono usate per operazioni di OUTPUT (e.g. scrivere il dato su disco)
- / Innescano l'esecuzione dell'intero DAG



DUBBI DUBBI



#### **DEMO!!!**



#### WWW.TOP-IX.ORG

twitter: @A\_Becca88

email: andrea.beccaris@top-

ix.org